

Su İçilebilirliği Tahmini

Makine Öğrenmesi Proje Raporu

Bu çalışmada, suya ait fizikokimyasal ölçümlerden yararlanarak örneklerin içilebilirlik durumunu tahmin etmeye çalıştım. Amaç, tek başına laboratuvar analizinin yerine geçecek bir sistem kurmak değil; mevcut ölçümlerle hangi sınıflandırma yönteminin daha iyi sonuç verdiğini görmektir. Bu nedenle veri seti incelendikten sonra eksik değerler düzenlendi, aykırı değerler sınırlandırıldı ve dört farklı model aynı işlem akışıyla karşılaştırıldı.

Veri ve hazırlık süreci

Kullanılan Water Potability veri setinde 3.276 su örneği bulunuyor. Her örnek için pH, sertlik, çözünmüş katı madde, kloramin, sülfat, iletkenlik, organik karbon, trihalometan ve bulanıklık olmak üzere dokuz özellik yer alıyor. Hedef değişken Potability; 1 içilebilir, 0 içilemez anlamına geliyor. Veri setinde 1.998 içilemez ve 1.278 içilebilir örnek var. Bu dağılım, içilebilir sınıfının daha az gözlemlendiğini gösteriyor; bu yüzden yalnızca doğruluk oranını yorumlamak yeterli değil.

pH sütununda 491, Sulfate sütununda 781 ve Trihalomethanes sütununda 162 eksik değer vardı. Verinin yüzde 70'i eğitim, yüzde 15'i doğrulama ve yüzde 15'i test için ayrıldı. Eksik değerler eğitim verisinden hesaplanan medyanla tamamlandı. Aykırı değerler IQR yöntemiyle belirlenip silinmek yerine alt ve üst sınırlara çekildi. Son olarak tüm özellikler StandardScaler ile ölçeklendirildi. Bu işlemlerin eğitim verisinden öğrenilmesi, test ve doğrulama verisinin önceden görülmesini engelledi.

Modellerin karşılaştırılması

Lojistik Regresyon, KNN, Random Forest ve XGBoost modelleri karşılaştırıldı. Model seçerken doğruluk değerinin yanında içilebilir sınıfı için precision, recall ve F1 skoru da dikkate alındı. Bu seçim önemliydi; örneğin bir model içilebilir örnekleri hiç tahmin etmese bile veri setindeki çoğunluk sınıfı nedeniyle kabul edilebilir görünen bir doğruluk elde edebilir.

Model	Doğruluk	Kesinlik	Duyarlılık	F1 Skoru
Lojistik Regresyon	0,631	0,000	0,000	0,000
KNN	0,611	0,465	0,365	0,409
Random Forest	0,664	0,577	0,331	0,421
XGBoost	0,654	0,540	0,409	0,465

Tablo 1. Doğrulama verisindeki sonuçlar

Doğrulama verisinde en yüksek doğruluk Random Forest ile 0,664 olarak elde edildi. İçilebilir sınıfın F1 skoru ise XGBoost'ta 0,465 ile daha yüksekti. Lojistik Regresyon içilebilir sınıfa ait tahmin üretmediği için F1 skoru sıfır kaldı. Bu nedenle modeli sadece doğruluğa bakarak değerlendirmek doğru olmaz. İçilebilir suyu yakalama hedefi açısından XGBoost daha dengeli bir sonuç verdiği için son değerlendirme için bu model seçildi.

XGBoost modeli test verisinde 0,652 doğruluk, 0,556 precision, 0,373 recall ve 0,447 F1 skoru verdi. Bu değerler modelin içilebilir örneklerin bir kısmını yakalayabildiğini, fakat

performansın gerçek karar verme süreçleri için hâlâ sınırlı olduğunu gösteriyor. Özellikle içilebilir olarak tahmin edilen her örneğin gerçekten içilebilir olduğundan emin olunamadığı için modelin çıktısı laboratuvar sonucu gibi kullanılmamalıdır.

Sonuç

Çalışmada kullanılan dört model arasında doğruluk bakımından Random Forest, içilebilir sınıfın F1 skoru bakımından ise XGBoost öne çıktı. Sonuçlar, veri setindeki ölçümlerin içilebilirlik etiketiyle ilişkili bazı örüntüler taşıdığını gösteriyor. Buna rağmen modelin başarısı orta düzeyde kaldı. Veri setindeki sınıf dağılımı ve özelliklerin sınırlı olması, özellikle içilebilir örnekleri bulmayı zorlaştırmış olabilir.

İleride çalışmayı geliştirmek için önce veri bölünürken sınıf oranlarını koruyan stratified bir ayırma kullanılabilir. Daha sonra aykırı değer kırpmasının gerçekten katkı sağlayıp sağlamadığı, kırılmış ve kırılmamış sonuçlar karşılaştırılarak ölçülebilir. XGBoost ve Random Forest için hiperparametre ayarı yapılması, karar eşiğinin doğrulama verisi üzerinde denenmesi ve çapraz doğrulama kullanılması da sonuçların daha güvenilir biçimde yorumlanmasına yardımcı olur. Bu proje, su kalitesi izleme sürecinde ön değerlendirme için faydalı olabilir; nihai içilebilirlik kararının ise laboratuvar analiziyle verilmesi gerekir.

Kaynakça

Kaggle. Water Potability veri seti.

<https://www.kaggle.com/datasets/uom190346a/water-quality-and-potability>

Turan, T. (2023). Makine Öğrenmesi Algoritmaları ile Su Kalitesi ve İçilebilirlik Tahmini. Uluborlu Mesleki Bilimler Dergisi, 6(2), 65-80.

Patel, J., Amipara, C., Ahanger, T. A. ve diğerleri. (2022). A Machine Learning-Based Water Potability Prediction Model by Using Synthetic Minority Oversampling Technique and Explainable AI. Computational Intelligence and Neuroscience, 2022.

Pedregosa, F. ve diğerleri. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.